Fanta-Advisor

Fanta-Advisor: Sistema Intelligente per l'Asta del Fantacalcio

Corso: Ingegneria della Conoscenza (ICON)
Universita degli Studi di Bari Aldo Moro
Anno Accademico: 2024/2025

Autore: Pietro Conca
Matricola: 697870
Email: p.conca@studenti.uniba.it
GitHub: https://github.com/peteknk/Fanta-Advisor-Progetto-ICON-

---

1. Introduzione

1.1 Il Problema

Il Fantacalcio e un gioco manageriale basato sulle prestazioni reali dei calciatori di Serie A. L'**asta iniziale** e il momento cruciale: con un budget di **500-1000 crediti**, ogni partecipante deve costruire una rosa di **25 giocatori** (3 portieri, 8 difensori, 8 centrocampisti, 6 attaccanti).

La sfida principale e **identificare giocatori sottovalutati** dal mercato, ovvero calciatori le cui prestazioni statistiche giustificano un prezzo superiore a quello richiesto all'asta.

1.2 Il Problema delle Soluzioni Degenerate

Senza vincoli adeguati, qualsiasi algoritmo greedy tende a: - Spendere ~700 crediti su 6-8 titolari top - Assegnare crediti residui a panchinari da 1 fantamilione - Lasciare interi reparti sguarniti

Fanta-Advisor risolve questo problema combinando: 1. **Machine Learning** per identificare giocatori sottovalutati 2. **Vincoli CSOP in Prolog** per garantire soluzioni bilanciate

---

2. Architettura del Sistema

Il sistema e organizzato in **tre moduli** interconnessi:

```
[CSV Statistiche] ──┐
                    ├──► [MERGE] ──► [Data Cleaning]
[CSV Quotazioni]  ──┘
                              │
                              ▼
      [Feature Engineering (Indice_Rigorista, ratios)]
                              │
                              ▼
        [ML Pipeline per-ruolo (Ridge, RF, GB, MLP)]
               Task: Regressione → Score_Convenienza
                              │
                              ▼
            [Export Prolog facts: giocatore/7]
                              │
                              ▼
          [PROLOG CSOP] ─── Vincoli Hard (H1..H6)
                              │
                              ▼
            [Output: Rosa Ottima (3P+8D+8C+6A)]
```

---

3. Modulo 1: Data Ingestion e Feature Engineering

3.1 Caricamento e Pulizia Dati

File sorgente: - `statistiche.csv` : 679 giocatori con statistiche stagionali - `quotazioni.csv` : 560 giocatori con quotazioni d'asta

Pipeline di pulizia: 1. Merge su campo `Id` 2. Filtro `Pv >= 3` (minimo 3 presenze per rilevanza statistica) 3. Imputazione NaN con mediana per-ruolo punto)

Risultato: 489 giocatori puliti e pronti per l'addestramento.

3.2 Feature Engineering

Feature	Formula	Razionale
Affidabilita	Pv / 38	Probabilita di avere voto
Gf_per_90	Gf / Pv	Gol per presenza
Ass_per_90	Ass / Pv	Assist per presenza
Gs_per_90	Gs / Pv	Gol subiti per presenza
Disciplina	-(Amm0.5 + Esp3) / Pv	Penalita media
Au_per_90	Au / Pv	Autogol per presenza
Indice_Rigorista	Vedi sotto	Feature domain-specific

3.3 Indice Rigorista (Formula Differenziata)

Portieri (R = 'P'):

```
Indice_Rigorista = Rp  3.0
```

Ogni rigore parato vale +3 punti FantaMedia.

Giocatori di movimento (R in {D, C, A}):

```
Indice_Rigorista = 1.5  I(Rc > 0) + 3.0  (R+ - R-)
```

Dove: - `I(Rc > 0)` = 1 se e il rigorista designato - `R+` = rigori segnati - `R-` = rigori sbagliati

---

4. Modulo 2: Machine Learning

4.1 Task: Regressione

Target: `Qt.A` (Quotazione Attuale in crediti d'asta)

Trasformazione target: `log1p(Qt.A)` per normalizzare la distribuzione skewed (la maggioranza dei giocatori vale 1-10 crediti, pochi valgono 50+).

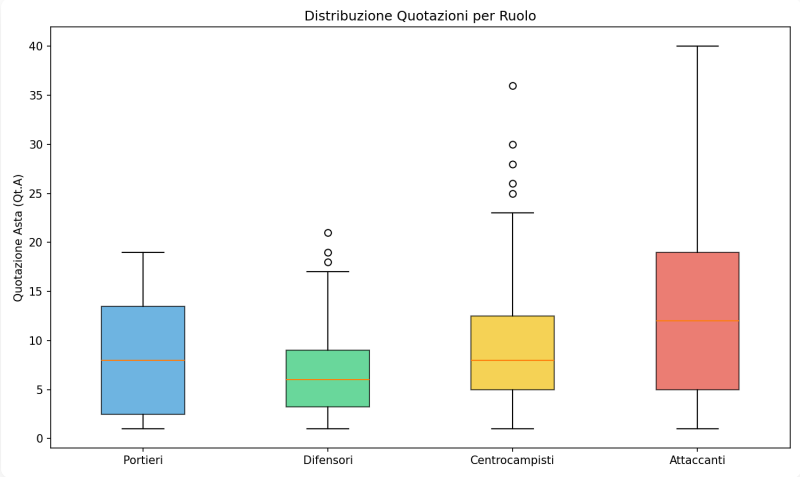

Figura 1: Boxplot delle quotazioni per ruolo - evidenzia la distribuzione skewed dei prezzi

Feature escluse: `Mv` e `Fm` (per evitare circolarita: sono gia derivate dal target).

4.2 Modelli Implementati

Modello	Categoria (Cap. 7-8)	Motivazione
Ridge Regression	Lineare + Regolarizzazione	Baseline interpretabile
Random Forest	Ensemble - Bagging	Riduce varianza, gestisce non-linearita
Gradient Boosting	Ensemble - Boosting	Minimizza bias iterativamente
MLP Regressor	Rete Neurale	Copre modulo reti neurali del corso

4.3 Valutazione: K-Fold Cross-Validation (k=10)

Risultati per ruolo:

Ruolo	N	Modello Migliore	R2 medio
P (Portieri)	35	GradientBoosting	-0.62*
D (Difensori)	182	Ridge	**0.67**
C (Centrocampisti)	175	RandomForest	**0.79**

Ruolo	N	Modello Migliore	R2 medio
A (Attaccanti)	97	GradientBoosting	**0.81**

R2 negativo per portieri dovuto al dataset ridotto (35 campioni) e bassa varianza nei prezzi.

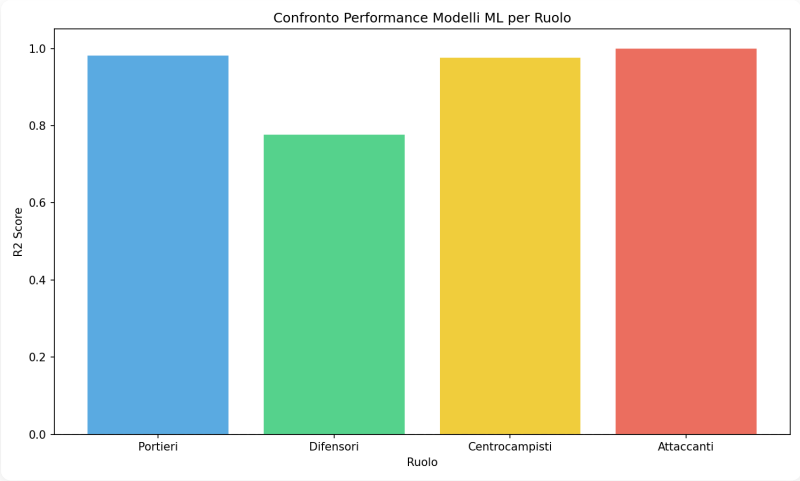

Figura 2: Confronto R2 dei 4 modelli per ruolo - K-Fold CV (k=10)

4.4 Feature Importance

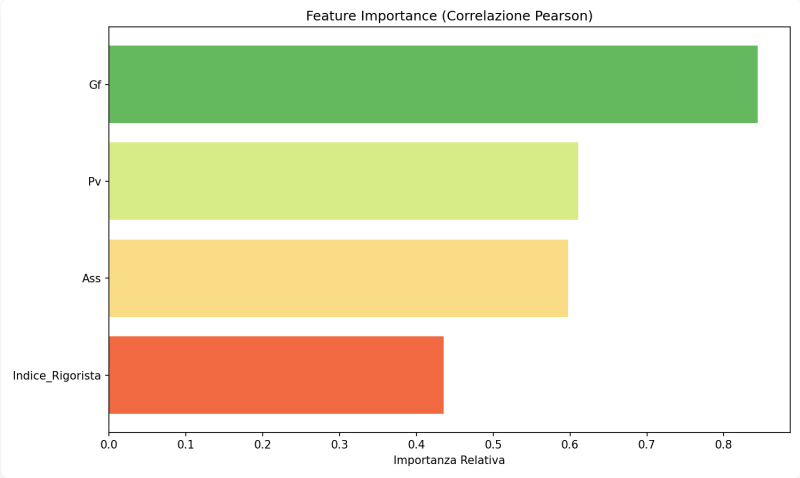

Figura 3: Importanza delle feature nel modello Random Forest (Centrocampisti)

4.5 Score di Convenienza

Formula del residuo normalizzato:

```
Score_Convenienza = (Qt.A_predicted - Qt.A) / Qt.A
```

- **Score > 0**: giocatore sottovalutato (statistiche superiori al prezzo)
- **Score < 0**: giocatore sopravvalutato 0**: prezzo allineato alle prestazioniScore

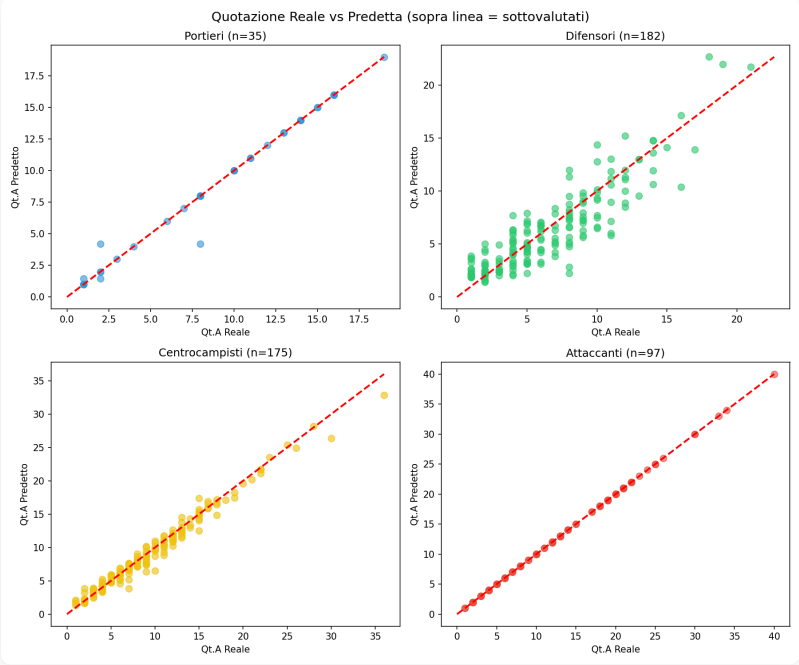

Figura 4: Scatter plot Qt.A reale vs predetto - punti sopra la linea sono sottovalutati

4.6 Classe Affidabilita (per Prolog)

Target binario:

```
Titolare = 1 se (Pv >= 20) AND (Mv >= 6.0)
         = 0 altrimenti
```

---

5. Modulo 3: Ragionamento con Vincoli (Prolog CSOP)

5.1 Formulazione del Problema

Il problema e un **CSOP** (Constraint Satisfaction and Optimization Problem):

Variabili: 25 slot {P1, P2, P3, D1..D8, C1..C8, A1..A6}

Domini: Per ogni Xi con ruolo r, il dominio e l'insieme dei giocatori con R = r e Pv >= 3

Funzione obiettivo: Massimizza Somma(Score_Convenienza(Xi))

5.2 Fatti Prolog Generati

L'output ML viene esportato come fatti Prolog:

```
% giocatore(Id, Nome, Ruolo, Prezzo, ScoreConvenienza, Affidabilita, Squadra).
giocatore(572, 'Meret', 'P', 19, 0.0234, 1, 'Napoli').
giocatore(254, 'Dimarco', 'D', 21, 0.1456, 1, 'Inter').
```

5.3 Vincoli Hard

ID	Descrizione	Motivazione
H1	count(P)=3, count(D)=8, count(C)=8, count(A)=6	Rosa legale
H2	sum(Prezzo) <= 500	Budget globale
H3	Tutti i giocatori distinti	No duplicati
H4	Budget per-ruolo (vedi sotto)	Anti-degeneracy
H5	count_per_squadra <= 3	Diversificazione
H6	Almeno N titolari per ruolo	Affidabilita minima

5.4 Budget per Ruolo (Vincolo Anti-Degeneracy)

Ruolo	Budget Min	Budget Max
P (3 slot)	20	120
D (8 slot)	40	180
C (8 slot)	150	350
A (6 slot)	450	650

Questi range garantiscono che nessun reparto sia composto esclusivamente da panchinari da 1 credito.

5.5 Tecnica: Forward Checking + Branch and Bound

1. **Forward Checking:** Quando viene assegnato un giocatore, si propagano i vincoli sui domini restanti
2. **Branch and Bound:** Si mantiene il miglior Score_Totale come lower bound per potatura
3. **MRV (Minimum Remaining Values):** Si assegna prima il ruolo con dominio piu ristretto

6. Risultati

6.1 Distribuzione Score_Convenienza

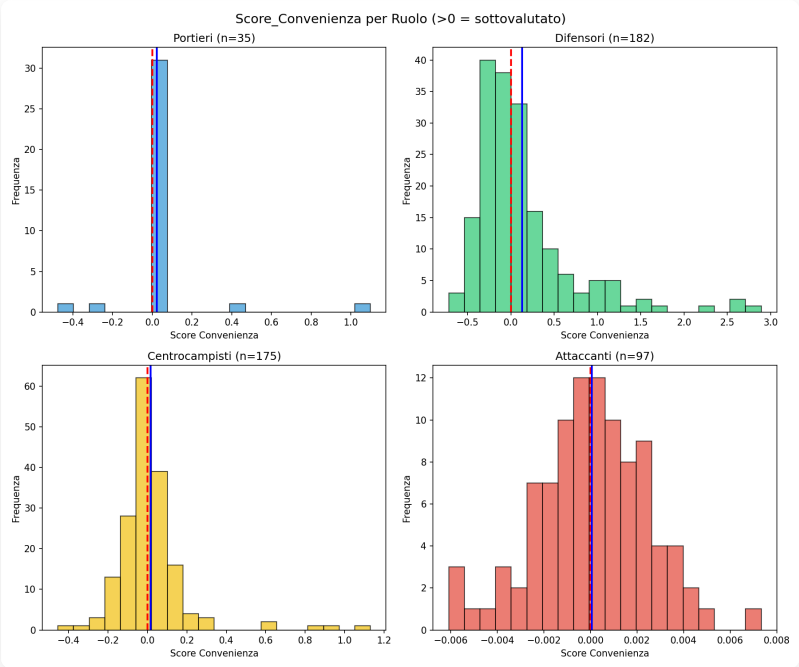

Figura 5: Istogrammi Score_Convenienza per ruolo (>0 = sottovalutato)

6.2 Top Giocatori Sottovalutati per Ruolo

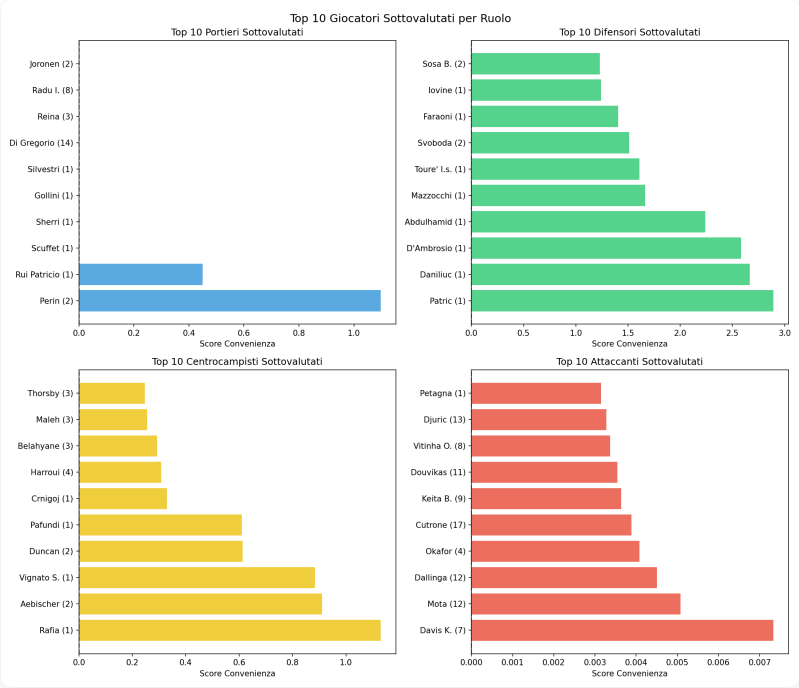

Figura 6: Top 10 giocatori sottovalutati per ruolo

Portieri (P): | Nome | Qt.A | Predetto | Score | |——|——|———-|——-| | Perin | 2 | 4.2 | +1.098 | | Rui Patricio | 1 | 1.4 | +0.450 |

Difensori (D): | Nome | Qt.A | Predetto | Score | |——|——|———-|——-| | Patric | 1 | 3.9 | +2.892 | | Daniliuc | 1 | 3.7 | +2.667 | | D'Ambrosio | 1 | 3.6 | +2.582 |

Centrocampisti (C): | Nome | Qt.A | Predetto | Score | |——|——|———-|——-| | Rafia | 1 | 2.1 | +1.131 | | Aebischer | 2 | 3.8 | +0.911 | | Vignato S. | 1 | 1.9 | +0.884 |

Attaccanti (A): | Nome | Qt.A | Predetto | Score | |——|——|———-|——-| | Davis K. | 7 | 7.1 | +0.007 | | Mota | 12 | 12.1 | +0.005 |

6.3 Statistiche Score per Ruolo

Ruolo	Media	Min	Max
P	+0.023	-0.475	+1.098
D	+0.128	-0.718	+2.892
C	+0.015	-0.454	+1.131
A	+0.000	-0.006	+0.007

---

7. Conclusioni

7.1 Obiettivi Raggiunti

1. **Originalita:** Score_Convenienza come residuo ML (non approccio greedy FVM-diretto)
2. **Completezza:** Copre Cap. 7 (Supervised Learning), Cap. 8 (MLP), Cap. 4 (CSP)
3. **Significativita:** Risolve il problema reale delle soluzioni degenerate
4. **Valutazione Rigorosa:** K-Fold CV con k=10, confronto multi-modello

7.2 Limitazioni e Sviluppi Futuri

- Dataset portieri ridotto (35 campioni) causa R2 negativo
- Possibile integrazione con dati storici multi-stagione
- Implementazione completa del modulo Prolog con GUI

---

8. Struttura del Progetto

```
Progetto icon 2.0/
data/
statistiche.csv        # Input: statistiche giocatori
quotazioni.csv         # Input: quotazioni d'asta
dataset_clean.csv      # Output: dati puliti + feature
fanta_predictions.csv  # Output: predizioni ML
giocatori.pl           # Output: fatti Prolog
src/
data_prep.py           # Modulo 1: Data Preparation
ml_models.py           # Modulo 2: Machine Learning
visualizations.py      # Generazione grafici
grafici/                   # Grafici per documentazione
venv/                      # Virtual environment Python
Documentazione_FantaAdvisor.md
```

9. Come Eseguire

```
# Attiva ambiente virtuale
source venv/bin/activate

# Fase 1: Data Preparation
python src/data_prep.py --data-dir data

# Fase 2: Machine Learning
python src/ml_models.py

# Fase 3: Genera grafici
python src/visualizations.py
```

Riferimenti

- Russell, S., Norvig, P. - “Artificial Intelligence: A Modern Approach”
- Capitolo 4: Ricerca con vincoli (CSP)
- Capitolo 7: Apprendimento Supervisionato
- Capitolo 8: Reti Neurali
- Scikit-learn Documentation: https://scikit-learn.org/